Julia Chmaj

Link do repozytorium: https://github.com/Jull22/IO-projekt2

SPRAWOZDANIE 2

Wybrana przeze mnie baza do analizy to "Telco Customer Churn". Składa się z 7043 wierszy i 21 kolumn. Kolumny zawierają informacje o klientach firmy dostarczającej usługi internetowe i telefoniczne.

Celem projektu jest zbadanie klasyfikatorów, które najlepiej wskażą przewidywania dotyczące rezygnacji klientów z dostarczanych usług- kolumna "Churn" .

Male	Female	Female	Male	Male	Male	Female	gender
C	0	0	0	0	0	0	SeniorCitizen
No	No	No	No	No	No	Yes	Partner
Yes	No	No	No	No	No	No	Dependents
22	8	2	45	2	34	1	tenure
Yes	Yes	Yes	No	Yes	Yes	No	PhoneService
Yes	Yes	No	No phone service	No	No	No phone service	MultipleLines
Fiber option	Fiber optic	Fiber optic	DSL	DSL	DSL	DSL	InternetService
No	No	No	Yes	Yes	Yes	No	OnlineSecurity
Yes	No	No	No	Yes	No	Yes	OnlineBackup
No	Yes	No	Yes	No	Yes	No	DeviceProtection
No	No	No	Yes	No	No	No	TechSupport
Yes	Yes	No	No	No	No	No	StreamingTV
No	Yes	No	No	No	No	No	StreamingMovies
Month-to- month	Month-to- month	Month-to- month	One year	Month- to- month	One year	Month-to- month	Contract
Yes	Yes	Yes	No	Yes	No	Yes	PaperlessBilling
Credit card (automatic	Electronic check	Electronic check	Bank transfer (automatic)	Mailed check	Mailed check	Electronic check	PaymentMethod
89.1	99.65	70.7	42.3	53.85	56.95	29.85	MonthlyCharges
1949.4	820.5	151.65	1840.75	108.15	1889.5	29.85	TotalCharges
No	Yes	Yes	No	Yes	No	No	Churn

Postanowiłam usunąć kolumnę z ID klienta, ponieważ nic nie wnosiła do klasyfikacji, oraz zamieniłam typ kolumny "SeniorCitizen" na kategoryczną, a "TotalCharges" na float.

TVD	\Box	ΛΙ	NIV	Γ

gender	object
SeniorCitizen	category
Partner	object
Dependents	object
tenure	int64
PhoneService	object
MultipleLines	object
InternetService	object
OnlineSecurity	object
OnlineBackup	object
DeviceProtection	object
TechSupport	object
StreamingTV	object
StreamingMovies	object
Contract	object
PaperlessBilling	object
PaymentMethod	object
MonthlyCharges	float64
TotalCharges	float64
Churn	object

df.1snull().sum()	
	82.00

gender	9
SeniorCitizen	0
Partner	0
Dependents	0
tenure	0
PhoneService	0
MultipleLines	0
InternetService	0
OnlineSecurity	0
OnlineBackup	0
DeviceProtection	0
TechSupport	0
StreamingTV	0
StreamingMovies	0
Contract	0
PaperlessBilling	0
PaymentMethod	0
MonthlyCharges	0

11

TotalCharges

Churn

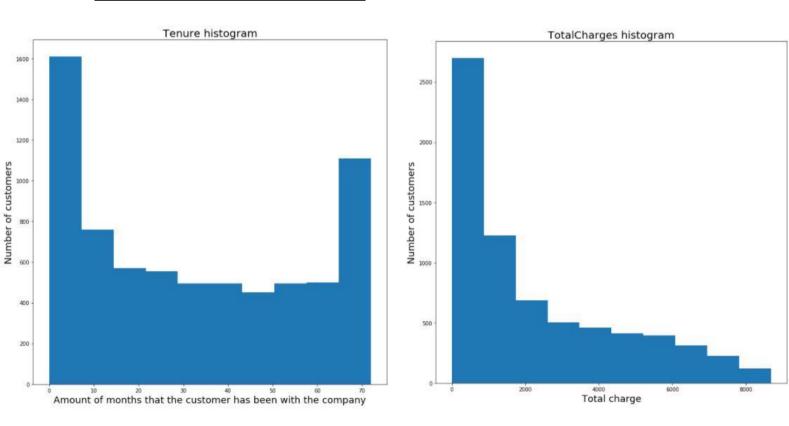
PUSTE WARTOŚCI

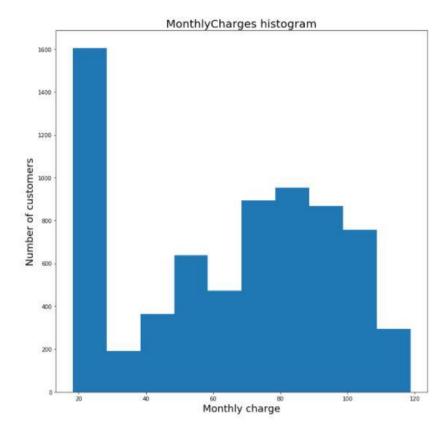
Tylko w jednej kolumnie znajduję braki danych i zastępuję je zerami.

Aby wyłuskać podstawowe informacje o danych (średnia, częstość występowania odpowiedzi, max, min) podzieliłam dane na numeryczne i kategoryczne.

	tenure	MonthlyCharges	TotalCharges
count	7043.000000	7043.000000	7043.000000
mean	32.371149	64.761692	2279.734304
std	24.559481	30.090047	2266.794470
min	0.000000	18.250000	0.000000
25%	9.000000	35.500000	398.550000
50%	29.000000	70.350000	1394.550000
75%	55.000000	89.850000	3786.600000
max	72.000000	118.750000	8684.800000

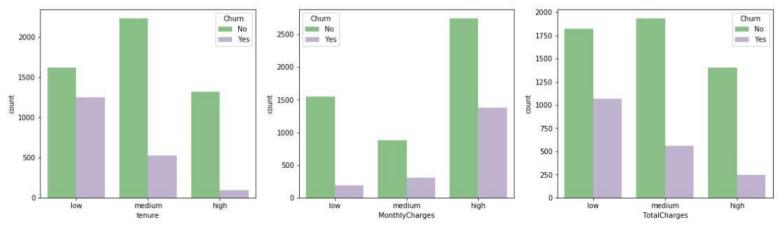
Histogramy danych numerycznych:





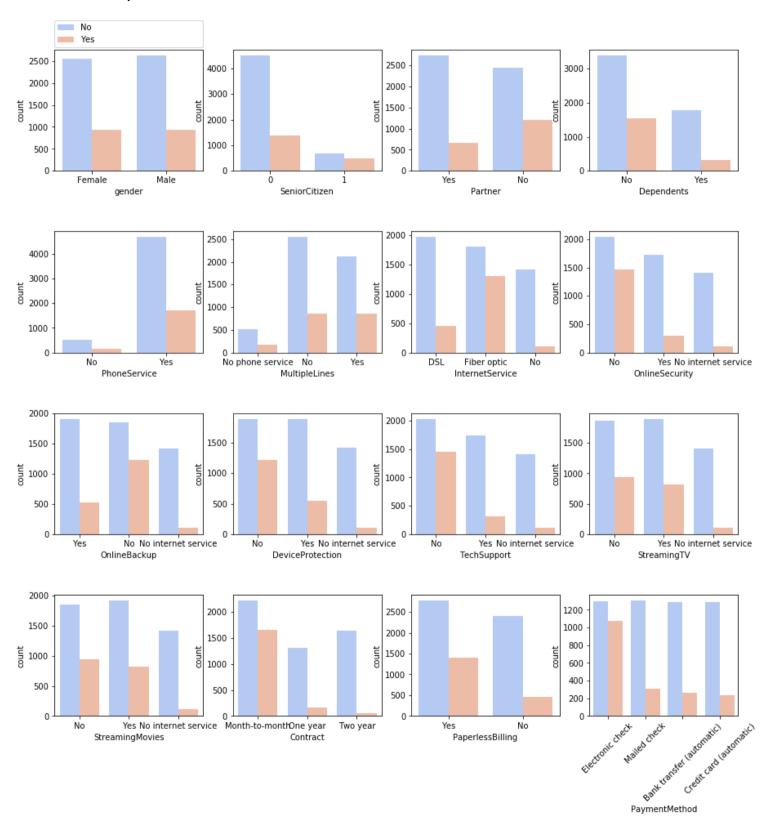
	count	unique	top	freq
gender	7043	2	Male	3555
SeniorCitizen	7043	2	0	5901
Partner	7043	2	No	3641
Dependents	7043	2	No	4933
PhoneService	7043	2	Yes	6361
MultipleLines	7043	3	No	3390
InternetService	7043	3	Fiber optic	3096
OnlineSecurity	7043	3	No	3498
OnlineBackup	7043	3	No	3088
DeviceProtection	7043	3	No	3095
TechSupport	7043	3	No	3473
StreamingTV	7043	3	No	2810
StreamingMovies	7043	3	No	2785
Contract	7043	3	Month-to-month	3875
PaperlessBilling	7043	2	Yes	4171
PaymentMethod	7043	4	Electronic check	238
Churn	7043	2	No	5174

W celu lepszego zobrazowania wartości danych numerycznych podzieliłam je na przedziały low/medium/high.



Histogramy danych kategorycznych:

Wskazują ile osób zrezygnowało z usług lub zostało, w zależności od danej cechy.

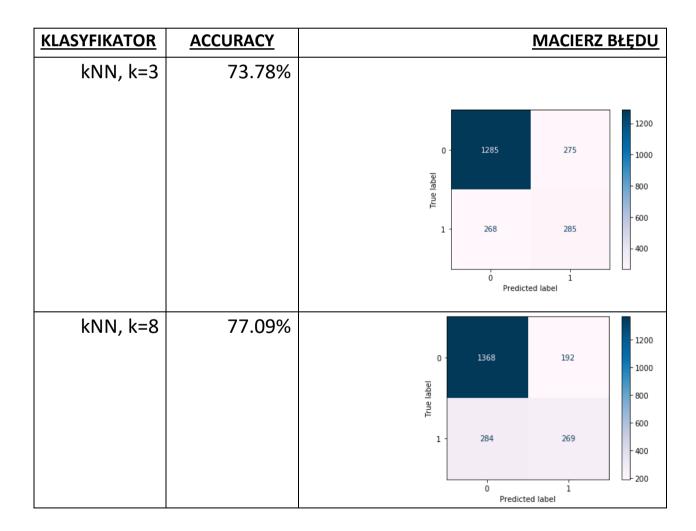


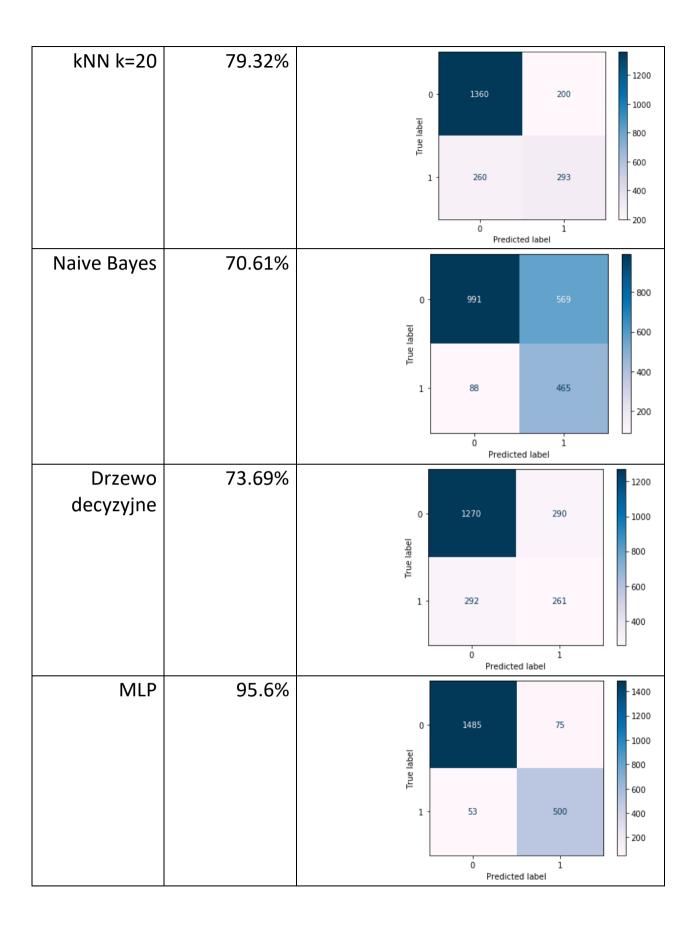
Baza danych do klasyfikacji składa się z danych numerycznych, które zostały podzielone na przedziały oraz danych kategorycznych rozdzielonych na kolumny, przez co wartości są 0-1.

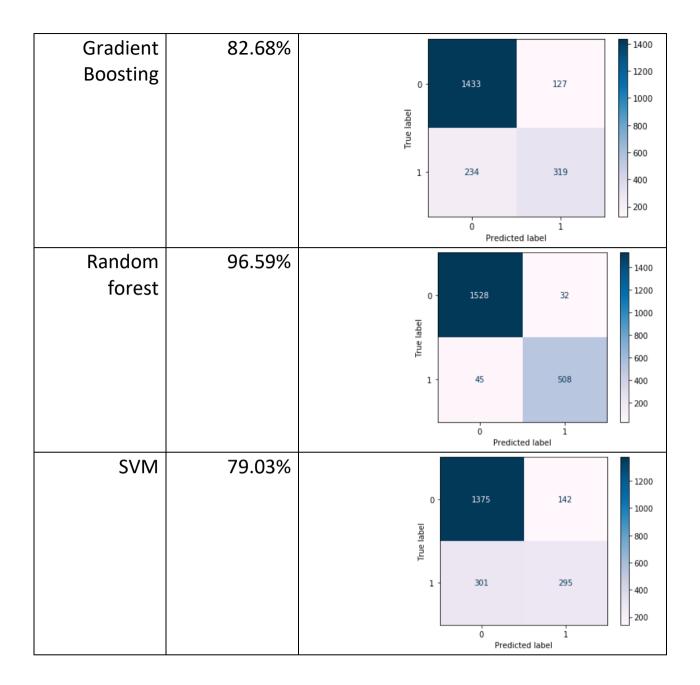
	0	1	2	3	4	5	6	7	8	9	***	7033	7034	7035	7036	7037	7038	7039	7040	7041	7042
tenure_high	0	0	0	0	0	0	0	0	0	1		0	1	0	0	1	0	1	0	0	1
tenure_low	1	0	1	0	1	1	0	1	0	0		0	0	1	1	0	0	0	1	1	0
tenure_medium	0	1	0	1	0	0	1	0	1	0		1	0	0	0	0	1	0	0	0	0
MonthlyCharges_high	0	0	0	0	1	1	1	0	1	0		1	1	1	1	0	1	1	0	1	1
Monthly Charges_low	1	0	0	0	0	0	0	1	0	0		0	0	0	0	1	0	0	1	0	0
MonthlyCharges_medium	0	1	1	1	0	0	0	0	0	1		0	0	0	0	0	0	0	0	0	0
TotalCharges_high	0	0	0	0	0	0	0	0	0	0		0	1	0	0	0	0	1	0	0	1
TotalCharges_low	1	0	1	0	1	1	0	1	0	0	1000	0	0	0	1	0	0	0	1	1	0
TotalCharges_medium	0	1	0	1	0	0	1	0	1	1		1	0	1	0	1	1	0	0	0	0
gender_Female	1	0	0	0	1	1	0	1	1	0	0.5	0	1	0	1	1	0	1	1	0	0
gender_Male	0	1	1	1	0	0	1	0	0	1		1	0	1	0	0	1	0	0	1	1
SeniorCitizen_0	1	1	1	1	1	1	1	1	1	1		1	1	1	1	1	1	1	1	0	1
SeniorCitizen_1	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	0	0	0	1	0
Partner_No	0	1	1	1	1	1	1	1	0	1		1	1	1	1	1	0	0	0	0	1
Partner_Yes	1	0	0	0	0	0	0	0	1	0		0	0	0	0	0	1	1	1	1	0
Dependents_No	1	1	1	1	1	1	0	1	1	0		1	1	1	1	1	0	0	0	1	1
Dependents_Yes	0	0	0	0	0	0	1	0	0	1		0	0	0	0	0	1	1	1	0	0
PhoneService_No	1	0	0	1	0	0	0	1	0	0		0	0	0	1	0	0	0	1	0	0
PhoneService_Yes	0	1	1	0	1	1	1	0	1	1	555	1	1	1	0	1	1	1	0	1	1
MultipleLines_No	0	1	1	0	1	0	0	0	0	1		1	0	1	0	1	0	0	0	0	1
MultipleLines_No phone service	1	0	0	1	0	0	0	1	0	0		0	0	0	1	0	0	0	1	0	0
MultipleLines_Yes	0	0	0	0	0	1	1	0	1	0	12.5	0	1	0	0	0	1	1	0	1	0
InternetService_DSL	1	1	1	1	0	0	0	1	0	1	225	0	0	0	1	0	1	0	1	0	0
InternetService_Fiber optic	0	0	0	0	1	1	1	0	1	0		1	1	1	0	0	0	1	0	1	1
InternetService_No	0	0	0	0	0	0	0	0	0	0		0	0	0	0	1	0	0	0	0	0
OnlineSecurity_No	1	0	0	0	1	1	1	0	1	0		1	0	1	1	0	0	1	0	1	0

KLASYFIKATORY

- 1.kNN (dla k= 3,8,20)
- 2. Naive Bayes
- 3.Drzewo Decyzyjne
- 4. Multi-layer Perceptron
- 5. Gradient Boosting- wykorzystuje metodę spadku gradientu
- 6. Random Forest- złożony z drzew decyzyjnych
- 8. Support Vector Machines
- 7. Neural Network







Sieć neuronowa

Sieć wykorzystuje funkcję aktywacji "selu" oraz "softmax".

```
model = keras.Sequential()
model.add(keras.layers.Dense(52,activation="selu",kernel_initializer= "he_normal",input_dim = X_train.shape[1]))
model.add(keras.layers.BatchNormalization())
model.add(keras.layers.Dense(52,activation="selu",kernel_initializer= "he_normal"))
model.add(keras.layers.BatchNormalization())
model.add(keras.layers.Dense(20,activation="selu",kernel_initializer= "he_normal"))
model.add(keras.layers.BatchNormalization())

model.add(keras.layers.Dense(2,activation="softmax"))
model.add(keras.layers.Dense(2,activation="softmax"))
model.compile(optimizer='adam',loss="sparse_categorical_crossentropy", metrics=["accuracy"])
model.summary()
```

Model: "sequential_44"

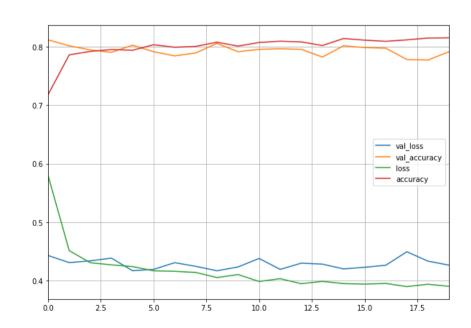
Layer (type)	Output	Shape	Param #
dense_187 (Dense)	(None,	52)	2756
batch_normalization_27 (Batc	(None,	52)	208
dense_188 (Dense)	(None,	52)	2756
batch_normalization_28 (Batc	(None,	52)	208
dense_189 (Dense)	(None,	20)	1060
batch_normalization_29 (Batc	(None,	20)	80
dense_190 (Dense)	(None,	2)	42

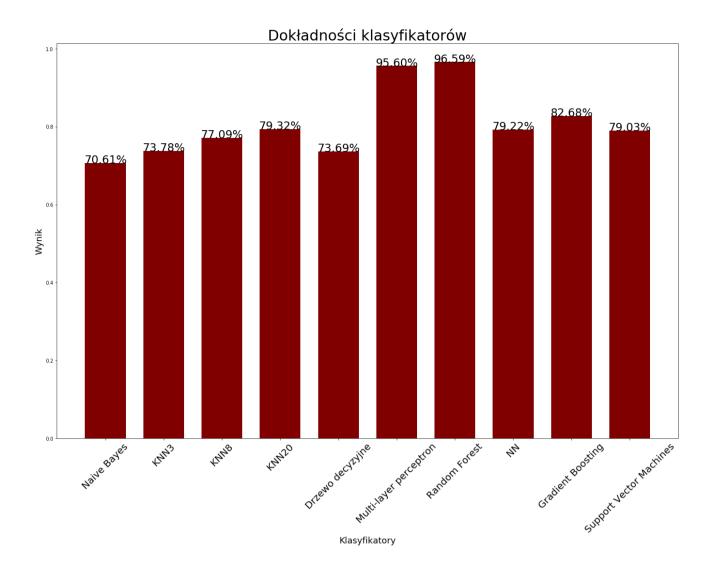
Total params: 7,110 Trainable params: 6,862 Non-trainable params: 248

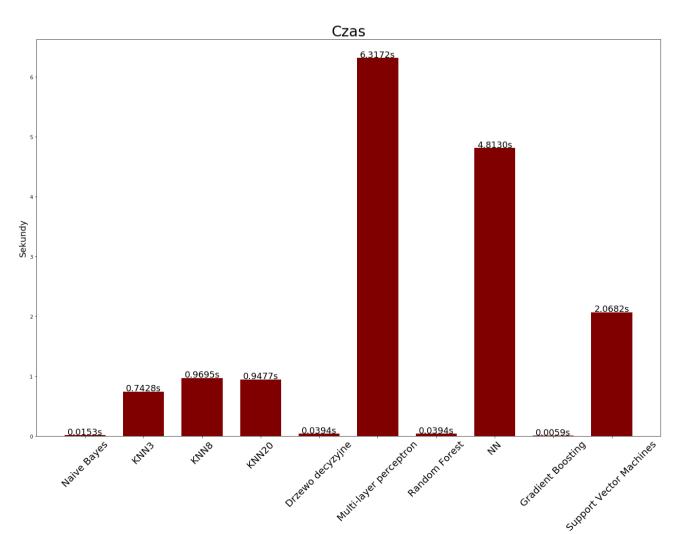
Accuracy: 79.22%

Macierz błędu:

	0	1
0	1421	131
1	382	179







Reguły asocjacyjne

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	leverage	conviction
0	(PhoneService_Yes)	(SeniorCitizen_0)	0.903168	0.837853	0.755788	0.836818	0.998765	-0.000935	0.993657
1	(SeniorCitizen_0)	(PhoneService_Yes)	0.837853	0.903166	0.755786	0.902050	0.998765	-0.000935	0.988609
2	(Churn_No)	(SeniorCitizen_0)	0.734630	0.837853	0.640068	0.871279	1.039895	0.024556	1.259681
3	(SeniorCitizen_0)	(Chum_No)	0.837853	0.734630	0.640068	0.763938	1.039895	0.024556	1.124155
4	(PhoneService_Yes)	(Dependents_No)	0.903166	0.700412	0.632827	0.700676	1.000377	0.000239	1.000883
5	(Dependents_No)	(PhoneService_Yes)	0.700412	0.903166	0.632827	0.903507	1.000377	0.000239	1.003531
6	(PhoneService_Yes)	(Chum_No)	0.903166	0.734630	0.661934	0.732904	0.997650	-0.001559	0.993536
7	(Churn_No)	(PhoneService_Yes)	0.734630	0,903166	0.661934	0.901044	0.997650	-0.001559	0.978550